COLLEGIUM DA VINCI

SYLABUS MODUŁU KSZTAŁCENIA

Nazwa modułu: Analiza danych	Nazwa modułu w j. obcym: Data analysis	Język wykładowy: polski	Status modułu: Obowiązkowy
Wydział: Nauk Stosowanych	Kierunek: Informatyka	Specjalizacja: Moduły kierunkowe obligatoryjne	Poziom kształcenia: Studia drugiego stopnia
Cykl kształcenia: 2024-2027	Rok studiów: 1(stac.) / 1 (niestac.)	Semestr studiów: II (stac.)/II (niestac.)	Tryb studiów: Stacjonarne / Niestacjonarne
Liczba godzin: 50 (stac.) / 30 (niestac.)	Liczba punktów ECTS: 5 (stac.) / 5 (niestac.)	Koordynator: Nadia Sikorska-Porawska	

Struktura modułu:
1. Zaawansowana eksploracja danych forma zajęć: Laboratorium (30h) (stac.) / Laboratorium (18h) (niestac.)
2. Technologie przetwarzania dużych zbiorów danych forma zajęć: Laboratorium (20h) (stac.) / Laboratorium (12h) (niestac.)

1. Opis modułu:
Celem modułu jest zapoznanie studentów z pojęciami, metodami i algorytmami technologii eksploracji danych oraz z dostępnymi rozwiązaniami technologicznymi i nowoczesnymi koncepcjami przetwarzania danych.

2. Cel (cele) modułu kształcenia

C1 - Przekazanie studentom podstawowej wiedzy na temat zaawansowanych algorytmów eksploracji złożonych danych oraz procesu odkrywania z nich wiedzy.

C2 - Przygotowanie studentów do przeprowadzania samodzielnej analizy z obszaru Big Data, wyboru odpowiednich narzędzi oraz interpretacji otrzymanych wyników.

C3 - Zrozumienie korzyści, wyzwań i problemów jakie generuje posługiwanie się Big Data w obszarze działalności biznesowej i naukowej.

C4 - Zapoznanie studentów z dostępnymi rozwiązaniami technologicznymi i nowoczesnymi koncepcjami przetwarzania danych.

3.Wymagania wstępne

a) Osiągnięcie efektów wynikających z realizacji przedmiotów:

4. Efekty uczenia się

Symbol efektów uczenia się	Opis efektów uczenia się
Po zakończeniu modułu (przedmiotu) i potwierdzeniu osiągnięcia efektów uczenia się student w zakresie **wiedzy:**	
W1	Student ma zaawansowaną wiedzę o osiągnięciach w eksploracji danych, zwłaszcza w odniesieniu do danych złożonych.
W2	Student ma wiedzę związaną z takimi zagadnieniami jak eksploracja strumieni danych, metody wizualnej eksploracji danych, rozpraszania eksploracji danych na wiele maszyn obliczeniowych, wybranych klasyfikatorów.
W3	Student charakteryzuje metody, techniki i narzędzia stosowane przy rozwiązywaniu złożonych zadań z zastosowaniem algorytmów eksploracji danych oraz zagadnienia danych relacyjnych.

Po zakończeniu modułu (przedmiotu) i potwierdzeniu osiągnięcia efektów uczenia się student w zakresie **umiejętności:**	
U1	Student łączy wiedzę z różnych obszarów informatyki związanych z pozyskiwaniem danych z różnych źródeł, ich przetwarzaniem oraz eksploracją, oceną uzyskanych wzorców i zastosowaniem znalezionych modeli.
U2	Dobiera metodę analizy danych do problemu badawczego i istniejących potrzeb informacyjnych.
U3	Buduje modele danych w oparciu o różnorodne narzędzia statystyczne i niestatystyczne.
U4	Student wykorzystuje metody eksploracji danych z zakresu klasyfikacji, regresji, asocjacji oraz klastrowania.

Po zakończeniu modułu (przedmiotu) i potwierdzeniu osiągnięcia efektów uczenia się student w zakresie **kompetencji społecznych:**	
K1	Student rozumie istotność wykorzystywania najnowszej wiedzy z eksploracji danych i uczenia maszynowego w rozwiązywaniu problemów badawczych i praktycznych.
K2	Student rozumie potrzebę korzystania z różnych metod analizy danych dla lepszego postrzegania, opisu i analizy otaczającej rzeczywistości.
K3	Student potrafi współpracować w zespole przyjmując różne role przy realizacji projektu w zakresie analizy dużych zbiorów danych.

5. Kompetencje przyszłości:
Analizowanie danych / Data analysis
Kreatywność / Creativity
Elastyczność / Flexibility
Radzenie sobie ze stresem/praca pod presją czasu / Dealing with stress/working under time pressure
Logiczne myślenie / Logical thinking

6. Treści kształcenia

Nazwa modułu: Analiza danych	
Symbol treści kształcenia	**Opis treści kształcenia**
Zaawansowana eksploracja danych, Laboratorium	
1.1	Charakterystyka procesu odkrywania wiedzy w bazach danych.
1.2	Główne metody przetwarzania wstępnego danych (w szczególności łączenie danych z różnych źródeł, oczyszczenie danych z błędów, uwzględnianie braków danych).
1.3	Redukcja wymiarowości danych (selekcja cech, tworzenie nowych cech, metody projekcji do przestrzeni niskowymiarowych, SVD), transformacje oraz metody dyskretyzacji.
1.4	Modele eksploracji danych: klasyfikacja, regresja, szeregi czasowe oraz odkrywanie wiedzy: analiza odchyleń, analiza skupień, analiza koszykowa.
1.5	Przykłady wykorzystania: eksploracja sieci web, systemy rekomendacyjne, eksploracja tekstu, analiza sentymentu.
Technologie przetwarzania dużych zbiorów danych, Laboratorium	
2.1	Koncepcja dużych zbiorów danych, definicje i charakterystyka. Model 4V i jego rozwinięcia.
2.2	Wprowadzenie do eksploracji danych w Big Data. Wyzwania technologiczne (algorytm MapReduce) i analityczne (jakość danych, preprocessing danych).
2.3	Technologia przetwarzania dużych zbiorów danych. Model i architektura przetwarzania Map-Reduce. Platforma Spark, paltforma Hadoop. Algorytmy i struktury danych: red-black tree, AVL-tree, T-tree, haszowanie liniowe.
2.4	Technologia przetwarzania rozproszonych zbiorów danych: fragmentacja, partycjonowanie i sharding danych, fragmentacja danych.
2.5	Bazy danych klasy NoSQL ich modele logiczne oraz wydajność.

7. Praktyczność
Kurs Zaawansowana eksploracja danych - Praktyczny Feedback, Kompetencje prowadzącego, Narzędzie pracy projektowej, Prezentacja finalnego rozwiązania
Kurs Technologie przetwarzania dużych zbiorów danych - Praktyczny Feedback, Kompetencje prowadzącego, Narzędzie pracy projektowej, Prezentacja finalnego rozwiązania

8. Warunki zaliczenia

Warunkiem zaliczenia jest otrzymanie pozytywnej oceny w ramach modułu. W ramach obydwu kursów podstawę zaliczenia stanowi projekt wykorzystujący metody zaawansowanej eksploracji danych oraz zadania realizowane w ramach zajęć. Kurs "Zaawansowana eksploracja danych" stanowi 50% oceny modułu. Kurs "Technologie przetwarzania dużych zbiorów danych" stanowi 50% oceny modułu.

Kryteria oceny:

Zakres ocen:	Skala ocen:
poniżej 3,00 - niedostateczna (2.0) od 3,00 do 3,25 - dostateczna (3.0) od 3,26 do 3,75 - dostateczna plus (3.5) od 3,76 do 4,25 - dobra (4.0) od 4,26 do 4,75 - dobra plus (4.5) od 4,76 do 5,0 - bardzo dobra (5.0) powyżej 5,01 – celująca (5.5).	2.0 – niedostateczna 3.0 – dostateczna 3.5 – dostateczna plus 4.0 – dobra 4.5 – dobra plus 5.0 – bardzo dobra 5.5 – celująca (wymaga sporządzania pisemnego uzasadnienia przez prowadzącego zajęcia)

9. *Zalecana literatura*

Literatura podstawowa:

1. Leskovec J., Rajaraman A., Ullman J., Mining of Massive Datasets, Stanford University, 2019.

2. Trovati M., Hill R., Anjum A., Zhu S.Y., L. Liu, Big-Data Analytics and Cloud Computing Theory, Algorithms and Applications, Springer International Publishing, 2015.

3. Han J., Kamber M., Pei J., Data Mining Concepts And Techniques, Elsevier, 2012.

Literatura uzupełniająca:

1. Cukier K., Mayer-Schonberger V., Big data. Efektywna analiza danych, MT Biznes, 2017.

2. Marinescu D., Cloud Computing: Theory and Practice, Morgan Kaufmann, 2013.

3. Ryza S., Laserson U., Owen S., Wills J. , Spark. Zaawansowana analiza danych, Helion, 2016.

4. White T. , Hadoop. Kompletny przewodnik. Analiza i przechowywanie danych, , Helion, 2016.

Inne źródła, np. linki, aplikacje, filmy, itp: